

Reconocimiento de Actividades en Parques Infantiles mediante Redes Neuronales de Grafos Panorámicos Multiescala

Antoine Ganem Nuñez¹, Hector Emil Grijalva Sanchez¹, Roberto Anwar Teigeiro Aguilar¹, and Fernando Antonio López García¹

Tecnológico de Monterrey, Monterrey, México
{A01644024, A01643459, A01643651, A01643685}@tec.mx

Abstract. El reconocimiento automático de actividades humanas en video constituye un problema fundamental en visión por computadora con aplicaciones en seguridad, análisis de comportamiento y monitoreo urbano inteligente. En este trabajo se presenta una adaptación sistemática del modelo MP-GCN (Multi-Person Graph Convolutional Network), originalmente propuesto para el reconocimiento de actividades grupales en voleibol, hacia un nuevo dominio de aplicación: parques infantiles públicos. El proyecto aborda múltiples desafíos técnicos incluyendo variaciones significativas en el número de personas presentes, diferencias espaciales entre múltiples cámaras panorámicas, integración explícita de objetos estáticos del entorno como nodos de grafo, y ventanas temporales de 32 frames. Se implementa una arquitectura multi-stream denominada PlaygroundGCN con cuatro representaciones complementarias (Joint, Bone, Joint Motion, Bone Motion) procesadas mediante backbones ST-GCN independientes con fusión tardía. Se describe el pipeline completo desde la extracción de poses esqueléticas mediante YOLOv8 y seguimiento ByteTrack, hasta la construcción de grafos panorámicos espaciotemporales y el entrenamiento del modelo adaptado. El dataset comprende 765 videos capturados de múltiples cámaras, de los cuales aproximadamente 500 fueron etiquetados manualmente utilizando Label Studio. Los resultados experimentales alcanzan una exactitud del 82.54% y un F1-score ponderado de 0.78 en la clasificación de 5 actividades relevantes en parques infantiles. Se discuten las limitaciones actuales y se proponen direcciones futuras de investigación.

Keywords: Reconocimiento de Actividades · Redes Neuronales de Grafos · Grafos Panorámicos · Computer Vision · Deep Learning · Análisis Espaciotemporal.

1 Introducción

El reconocimiento automático de actividades humanas en secuencias de video representa uno de los problemas más desafiantes en el área de visión por computadora [2]. Esta tarea es particularmente relevante para aplicaciones modernas de análisis urbano, vigilancia inteligente, seguridad pública y comprensión

de dinámicas sociales en espacios públicos. Los parques infantiles constituyen entornos especialmente complejos para el análisis automatizado, caracterizados por la convergencia simultánea de múltiples personas con diferentes edades y tamaños, objetos estáticos con funcionalidades específicas (columpios, resbaladillas, bancas), interacciones humanas diversas y variaciones temporales difíciles de modelar mediante métodos tradicionales de clasificación.

Los enfoques tradicionales para reconocimiento de actividades basados en características manuales (HOG, SIFT, Dense Trajectories) han sido progresivamente reemplazados por arquitecturas de aprendizaje profundo [2]. En particular, las redes neuronales convolucionales en grafos (GCN) han demostrado capacidades superiores para modelar relaciones estructurales en datos no euclidianos, siendo particularmente efectivas cuando se combinan con representaciones esqueléticas del cuerpo humano [6].

El presente proyecto adapta de manera sistemática el modelo MP-GCN [1], una arquitectura estado del arte de grafos espaciotemporales multiescala diseñada originalmente para actividades grupales en voleibol, al dominio de parques infantiles. Esta adaptación implica abordar diversos desafíos técnicos:

- **Variabilidad en el número de personas:** Configuración para un máximo de $M = 6$ individuos simultáneos, requiriendo ajustes en la arquitectura del grafo panorámico.
- **Integración de objetos estáticos:** Incorporación explícita de 8 elementos físicos del entorno (columpios, bancas, resbaladillas) como nodos adicionales en el grafo, extendiendo la dimensión de vértices de $V = 17$ a $V' = 25$.
- **Arquitectura Multi-Stream:** Implementación de cuatro streams complementarios (Joint, Bone, Joint Motion, Bone Motion) para capturar diferentes aspectos del movimiento humano y sus dinámicas temporales.
- **Geometrías irregulares:** Manejo de cámaras panorámicas con distorsiones no lineales y ángulos de visión variables, requiriendo normalización espacial robusta.

El objetivo principal de este trabajo es evaluar empíricamente la capacidad del modelo MP-GCN adaptado para reconocer actividades cotidianas en parques como *juego normal con objetos*, *juego riesgoso*, *interacción social*, *tránsito* y *asistencia de adultos*, utilizando datos reales capturados en múltiples parques públicos bajo condiciones no controladas.

1.1 Contribuciones

Las principales contribuciones de este trabajo son:

1. Adaptación sistemática de MP-GCN desde voleibol hacia un entorno no estructurado (parques infantiles) con arquitectura multi-stream.
2. Pipeline completo de procesamiento desde video raw hasta predicciones de actividades, incluyendo extracción de poses, generación de streams (J, B, V), anotación de objetos, construcción de grafos y entrenamiento.

3. Evaluación experimental en datos reales con análisis detallado de métricas por clase.
4. Identificación de desafíos específicos del dominio y propuestas de trabajo futuro.

2 Trabajo Relacionado

2.1 Reconocimiento de Actividades Basado en Esqueletos

Los métodos basados en esqueletos han ganado popularidad debido a su robustez ante variaciones de apariencia, iluminación y fondo [2]. ST-GCN introdujo el uso de convoluciones en grafos para modelar la estructura esquelética temporal, superando a métodos basados en RNN y CNN tradicionales. Arquitecturas posteriores como 2s-AGCN y MS-G3D extendieron estos conceptos mediante grafos adaptativos y convoluciones multiescala.

2.2 Reconocimiento de Actividades Grupales

MP-GCN [1] representa el estado del arte en reconocimiento de actividades grupales mediante la construcción de grafos panorámicos que capturan tres niveles de relaciones: intra-persona (esqueleto individual), inter-persona (interacciones entre individuos) y persona-objeto (interacciones con el entorno). Esta representación multiescala permite al modelo capturar patrones complejos de coordinación grupal.

2.3 Detección y Seguimiento de Poses

YOLOv8-Pose [3] representa uno de los detectores de pose más eficientes actualmente, capaz de extraer keypoints en formato COCO (17 puntos) en tiempo real. ByteTrack [4] proporciona seguimiento robusto mediante asociación de detecciones de alta y baja confianza, manteniendo identidades consistentes incluso con oclusiones parciales.

3 Metodología

El pipeline propuesto consta de cuatro fases principales que transforman progresivamente videos raw en representaciones de grafos espaciotemporales adecuadas para entrenamiento de MP-GCN. La Figura ?? (conceptual) ilustra este proceso.

3.1 Extracción de Poses Esqueléticas con YOLOv8

Fundamento Técnico Se empleó YOLOv8-Pose [3], un detector unificado que predice simultáneamente bounding boxes y keypoints esqueléticos en formato

COCO. Para cada frame f_t en el tiempo t , el modelo genera un conjunto de detecciones:

$$\mathcal{D}_t = \{(b_i, \mathbf{k}_i, c_i)\}_{i=1}^{N_t} \quad (1)$$

donde $b_i \in \mathbb{R}^4$ representa el bounding box, $\mathbf{k}_i \in \mathbb{R}^{17 \times 3}$ contiene las coordenadas (x, y) y confianza $conf$ de los 17 keypoints COCO, y $c_i \in [0, 1]$ es la confianza de detección.

Keypoints COCO El formato COCO define 17 puntos clave del cuerpo humano:

- **Cabeza:** nariz (0), ojos izquierdo/derecho (1-2), orejas izquierda/derecha (3-4)
- **Torso:** hombros izquierdo/derecho (5-6), caderas izquierda/derecha (11-12)
- **Extremidades superiores:** codos izquierdo/derecho (7-8), muñecas izquierda/derecha (9-10)
- **Extremidades inferiores:** rodillas izquierda/derecha (13-14), tobillos izquierdo/derecho (15-16)

Formato de Salida YOLO Cada frame genera un archivo de texto con el formato estándar YOLO-Pose:

```
class_id cx cy w h kp1_x kp1_y kp1_conf ... kp17_x kp17_y kp17_conf
```

donde las coordenadas están normalizadas en el rango $[0, 1]$ respecto a las dimensiones del frame.

Volumen de Datos: Esta fase procesó un total de 765 videos provenientes de 7 cámaras diferentes distribuidas en múltiples parques (columpios_cam4, columpiosCam1-3, hundido_cam4/5/7), de los cuales aproximadamente 500 fueron etiquetados manualmente utilizando Label Studio. Se generaron archivos de labels por frame con sus correspondientes detecciones de pose para cada video.

3.2 Anotación de Objetos Estáticos del Entorno

Motivación A diferencia del voleibol donde el entorno es homogéneo (cancha rectangular), los parques contienen objetos físicos con ubicaciones fijas que influyen directamente en las actividades humanas. Incorporar estos objetos como nodos adicionales en el grafo permite al modelo aprender relaciones contextuales como "persona cerca de columpio $\rightarrow$ actividad de columpiar".

3.3 Proceso de Anotación de Actividades con Label Studio

Plataforma de Anotación Para el etiquetado de actividades en los videos se utilizó Label Studio [5], una plataforma de anotación de datos de código abierto que permite crear interfaces personalizadas para tareas de etiquetado. Label Studio fue seleccionado por las siguientes ventajas:

- **Interfaz web intuitiva:** Permite a múltiples anotadores trabajar simultáneamente desde cualquier navegador.
- **Soporte para video:** Capacidad nativa para reproducir y anotar secuencias de video.
- **Plantillas personalizables:** Configuración flexible de esquemas de anotación mediante XML.
- **Exportación JSON:** Formato de salida estructurado compatible con pipelines de machine learning.
- **Control de calidad:** Seguimiento de progreso y métricas de acuerdo inter-anotador.

Configuración del Proyecto Se configuró un proyecto en Label Studio con las siguientes especificaciones:

1. **Tipo de tarea:** Clasificación de video (video classification)
2. **Esquema de etiquetas:** Selección única (single-choice) entre las 5 clases de actividades definidas
3. **Datos de entrada:** Videos segmentados por cámara con metadatos asociados (nombre de cámara, timestamp, duración)

Formato de Anotaciones Las anotaciones exportadas desde Label Studio siguen el formato JSON estructurado:

```
{
  "data": {
    "video_name": "camera_videoname",
    "camera": "camera_name"
  },
  "annotations": [{
    "result": [{
      "type": "choices",
      "value": {
        "choices": ["Play_Object_Normal"]
      }
    }]
  }]
}
```

Este formato es procesado por el script `prepare_data.py` que:

1. Parsea el archivo JSON de anotaciones (`annotationsv2.json`)
2. Normaliza nombres de cámaras y videos para matching con datos de pose
3. Filtra clases excluidas (`no_activity`, `sliding`)
4. Asocia cada anotación con su directorio de labels YOLO correspondiente

Flujo de Trabajo de Anotación El proceso de anotación siguió el siguiente flujo:

1. **Importación:** Los videos procesados por YOLO-Pose se importaron a Label Studio con sus metadatos.
2. **Asignación:** Los videos se distribuyeron entre los miembros del equipo para anotación.
3. **Etiquetado:** Cada anotador visualizó el video completo y asignó la clase de actividad predominante.
4. **Revisión:** Se realizó revisión cruzada para casos ambiguos o transiciones entre actividades.
5. **Exportación:** Las anotaciones finales se exportaron en formato JSON para procesamiento.

Generación Automática de Tareas Para escalar el proceso de anotación, se desarrollaron scripts auxiliares:

- **generate_video_tasks_from_downloads.py:** Genera tareas de Label Studio desde videos descargados, creando metadatos JSON con información de cámara, timestamps y URLs de frames representativos.
- **generate_windows_tasks.py:** Crea tareas para anotación a nivel de ventana temporal (48 frames), permitiendo etiquetado granular de segmentos específicos cuando se requiere mayor precisión.

Estos scripts redujeron el tiempo de preparación de tareas de anotación de horas a minutos, permitiendo iterar rápidamente sobre diferentes estrategias de etiquetado.

Estructura del Archivo objects.yaml

```
camera_name:
  resolution: [2560, 1440]
  objects:
    - name: "columpio_1"
      type: "swing"
      centroid: [0.342, 0.521]
    - name: "banca_2"
      type: "bench"
      centroid: [0.781, 0.689]
```

Cobertura: Se anotaron 7 cámaras diferentes con objetos estáticos incluyendo columpios, resbaladillas, bancas de piedra y metal, juegos de piedra, trampolines, mesas metálicas y estructuras de escalada. Se utilizan 8 objetos por cámara ($n_{obj} = 8$) para construir el grafo panorámico.

3.4 Construcción de Grafos Panorámicos Espaciotemporales

Representación del Grafo Para cada ventana temporal de $T = 32$ frames, se construye un grafo panorámico $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathbf{X})$ donde:

- $\mathcal{V}$: conjunto de $V' = 25$ nodos por persona (17 keypoints COCO + 8 objetos estáticos)
- $\mathcal{E}$: conjunto de aristas definidas por la topología del esqueleto humano
- $\mathbf{X} \in \mathbb{R}^{4 \times 2 \times T \times V' \times M}$: tensor de características multi-stream

donde $M = 6$ es el número máximo de personas y los 4 streams corresponden a Joint (J), Bone (B), Joint Motion (JM) y Bone Motion (BM).

Generación de Streams Multi-modal El módulo de preprocesamiento implementa la generación de cuatro representaciones complementarias:

1. Joint Stream (J) - Posiciones de Keypoints:

$$\mathbf{J} = [\mathbf{x}, \mathbf{y}] \quad (2)$$

donde $(\mathbf{x}, \mathbf{y})$ son las coordenadas normalizadas de cada keypoint.

2. Bone Stream (B) - Vectores de Huesos:

Para cada joint i con padre $parent(i)$ según las conexiones COCO:

$$\mathbf{B}_i = \mathbf{k}_i - \mathbf{k}_{parent(i)} \quad (3)$$

3. Joint Motion Stream (JM) - Velocidad de Posiciones:

$$\mathbf{JM}_t = \mathbf{J}_t - \mathbf{J}_{t-1} \quad (4)$$

4. Bone Motion Stream (BM) - Velocidad de Huesos:

$$\mathbf{BM}_t = \mathbf{B}_t - \mathbf{B}_{t-1} \quad (5)$$

Las conexiones de huesos siguen la topología COCO:

- Cabeza: $0 \rightarrow 1, 0 \rightarrow 2, 1 \rightarrow 3, 2 \rightarrow 4$
- Brazos: $5 \rightarrow 7 \rightarrow 9, 6 \rightarrow 8 \rightarrow 10$
- Piernas: $11 \rightarrow 13 \rightarrow 15, 12 \rightarrow 14 \rightarrow 16$

Para los nodos de objetos (índices 17-24), el vector de hueso se calcula relativo al punto medio de las caderas (mid-hip):

$$\mathbf{B}_{obj} = \mathbf{k}_{obj} - \frac{\mathbf{k}_{11} + \mathbf{k}_{12}}{2} \quad (6)$$

Formato del Tensor de Entrada El tensor final de entrada al modelo tiene forma $(N, 4, 2, 32, 25, 6)$:

Table 1. Dimensiones del tensor de entrada al modelo PlaygroundGCN.

Dimensión	Descripción	Valor
N	Batch size	16
I	Número de streams (J, B, JM, BM)	4
C	Canales de features (x, y)	2
T	Frames temporales	32
V'	Nodos (17 keypoints + 8 objetos)	25
M	Máximo de personas	6

Integración de Objetos en el Grafo La función `add_object_nodes()` integra los objetos estáticos como nodos adicionales:

1. Se leen las coordenadas normalizadas del archivo `objects.yaml` para cada cámara
2. Los primeros 8 objetos se añaden como nodos 17-24 del grafo
3. Las coordenadas de objetos permanecen constantes a través de todos los frames y personas
4. La confianza de objetos se establece en 1.0

3.5 Preparación del Dataset y Splits

Generación de Ventanas Temporales Se aplica una ventana deslizante con los siguientes parámetros:

- Tamaño de ventana: $T = 32$ frames
- Stride: $s = 16$ frames (50% de solapamiento)

Dada una secuencia de video con F frames totales, el número de ventanas generadas es:

$$N_{\text{windows}} = \left\lfloor \frac{F - T}{s} \right\rfloor + 1 \quad (7)$$

Para videos con menos de 32 frames, se aplica zero-padding hasta alcanzar el tamaño requerido.

Etiquetado de Actividades Tras refinamiento iterativo del esquema de anotación, el modelo final reconoce 5 clases de actividades:

Table 2. Definición de clases de actividades en el modelo final.

Clase	Descripción
<code>Social_People</code>	Interacción social entre personas (conversación, juego grupal)
<code>Transit</code>	Personas caminando o transitando por el área sin interacción con objetos
<code>Play_Object_Normal</code>	Juego normal e interacción segura con equipamiento del parque (columpios, resbaladillas, etc.)
<code>Adult_Assisting</code>	Adulto asistiendo o supervisando niños en actividades del parque
<code>sliding</code>	Actividad específica de deslizarse en resbaladillas u otros equipos

Nota: Las clases `no_activity` y `Play_Object_Risk` fueron excluidas del entrenamiento final debido a su baja representación y ambigüedad semántica.

3.6 Splits del Dataset

El dataset se dividió siguiendo una estrategia de partición estratificada (80% entrenamiento, 20% validación):

Table 3. Distribución del dataset en splits de entrenamiento y validación.

Split	Muestras Porcentaje		Propósito
Entrenamiento	80%	Variable	Optimización de parámetros del modelo
Validación	20%	Variable	Selección de hiperparámetros y evaluación

Las muestras de clases con muy pocas instancias (< 2 muestras) se asignan directamente al conjunto de entrenamiento para evitar problemas en la estratificación.

4 Implementación del Modelo PlaygroundGCN

4.1 Arquitectura Multi-Stream

El modelo PlaygroundGCN implementado procesa cuatro streams en paralelo mediante backbones ST-GCN independientes por persona, fusionando las características mediante concatenación y una capa de fusión antes de la clasificación final:

$$\mathbf{F}_{\text{final}} = \text{FC} \left(\text{ReLU} \left(\text{Fusion} \left(\text{Concat} \left[\text{GAP}(\text{ST-GCN}_J), \right. \right. \right. \right. \\ \left. \left. \left. \text{GAP}(\text{ST-GCN}_B), \text{GAP}(\text{ST-GCN}_{JM}), \text{GAP}(\text{ST-GCN}_{BM}) \right] \right) \right) \right) \quad (8)$$

donde GAP denota Global Average Pooling, y los cuatro streams son: Joint (J), Bone (B), Joint Motion (JM) y Bone Motion (BM).

Spatial Graph Convolution Layer La capa de convolución espacial en grafos utiliza matrices de adyacencia aprendibles para modelar relaciones entre nodos:

$$\mathbf{H}^{(l+1)} = \sigma \left(\sum_{k=1}^K \text{softmax}(A_k) \mathbf{H}^{(l)} \mathbf{W}_k^{(l)} \right) \quad (9)$$

donde:

- $A_k \in \mathbb{R}^{V' \cdot M \times V' \cdot M}$: matriz de adyacencia aprendible para el subset k
- $K = 3$: número de subsets de adyacencia
- $\mathbf{W}_k^{(l)}$: parámetros de convolución para cada subset
- σ : función de activación ReLU

El número total de nodos en el grafo panorámico es $V' \times M = 25 \times 6 = 150$ nodos.

Temporal Convolution Layer Para capturar dependencias temporales, se aplican convoluciones 1D a lo largo de la dimensión temporal:

$$\mathbf{Y}_t = \sum_{\tau=-k}^k \mathbf{W}_\tau \cdot \mathbf{X}_{t+\tau} \quad (10)$$

con kernel size $k = 9$, padding calculado para mantener la dimensión temporal (cuando stride=1), y soporte para dilatación configurable.

ST-GCN Block El bloque básico ST-GCN combina ambas operaciones con conexiones residuales:

$$\mathbf{Z}_{\text{out}}^{(l)} = \text{ReLU} \left(\text{Dropout} \left(\text{TemporalConv} \left(\text{SpatialGraphConv} \left(\mathbf{Z}^{(l-1)} \right) \right) \right) + \text{Residual} \left(\mathbf{Z}^{(l-1)} \right) \right) \quad (11)$$

La conexión residual incluye proyección (Conv1x1 + BatchNorm) cuando las dimensiones de entrada y salida difieren o cuando stride > 1.

Backbone ST-GCN por Stream Cada stream utiliza 5 bloques ST-GCN con la siguiente configuración:

Table 4. Configuración de bloques ST-GCN por stream.

Bloque	Canales In	Canales Out	Stride	Nodos
1	4	64	1	100
2	64	64	1	100
3	64	128	2	100
4	128	128	1	100
5	128	256	2	100

Los strides de 2 en los bloques 3 y 5 reducen la dimensión temporal progresivamente.

Fusión y Clasificación

1. **Global Average Pooling:** Reduce cada stream de $(N, 256, T', V' \cdot M)$ a $(N, 256)$
2. **Concatenación:** Une los 4 streams en un vector de $256 \times 4 = 1024$ dimensiones
3. **Capa de Fusión:** Proyección lineal $1024 \rightarrow 512$ con ReLU y Dropout (0.3)
4. **Fully Connected:** Capa lineal $512 \rightarrow 5$ (número de clases)

4.2 Configuración de Entrenamiento

Table 5. Hiperparámetros utilizados durante el entrenamiento del modelo PlaygroundGCN.

Hiperparámetro	Valor
Optimizador	AdamW
Learning rate inicial	1×10^{-3}
Scheduler	Coseno con Warmup (5 épocas)
Épocas máximas	100
Época de mejor modelo	13
Batch size	16
Función de pérdida	CrossEntropyLoss con Label Smoothing
Label smoothing	0.1
Weight decay (L2)	1×10^{-4}
Dropout rate	0.3 (en capa de fusión)
Hidden channels base	64
Número de streams	4 (J, B, JM, BM)
Número de personas	6
Dispositivo	NVIDIA GPU (CUDA)

Focal Loss Para manejar el desbalance de clases, se utiliza Focal Loss con label smoothing:

$$\mathcal{L}_{FL} = -\alpha(1 - p_t)^\gamma \log(p_t) \quad (12)$$

donde p_t es la probabilidad predicha para la clase correcta, $\alpha = 1.0$ es el factor de balance, y $\gamma = 2.0$ es el factor de enfoque que reduce el peso de ejemplos fáciles.

OneCycleLR Scheduler El scheduler OneCycleLR implementa:

- Warm-up inicial hasta el learning rate máximo
- Decaimiento coseno hasta un learning rate mínimo
- Ciclo completo a lo largo de todas las épocas

4.3 Técnicas de Aumento de Datos

Para mejorar la generalización y robustez del modelo, se aplican las siguientes transformaciones aleatorias durante el entrenamiento (sin rotación, para preservar la semántica espacial):

- **Mirror/Flip Horizontal** (50% probabilidad): Inversión de coordenada x con intercambio de joints izquierda-derecha según pares COCO:

$$x' = 1.0 - x, \quad \text{swap}(joint_{left}, joint_{right}) \quad (13)$$

Pares intercambiados: (1,2), (3,4), (5,6), (7,8), (9,10), (11,12), (13,14), (15,16)

- **Gaussian Noise** (60% probabilidad): Ruido gaussiano $\epsilon \sim \mathcal{N}(0, 0.015)$

$$\mathbf{k}' = \text{clip}(\mathbf{k} + \epsilon, 0, 1) \quad (14)$$

- **Scale** (40% probabilidad): Factor de escala $s \sim \mathcal{U}(0.92, 1.08)$ centrado en 0.5

$$x' = 0.5 + (x - 0.5) \cdot s, \quad y' = 0.5 + (y - 0.5) \cdot s \quad (15)$$

- **Temporal Shift** (40% probabilidad): Desplazamiento temporal $\Delta t \sim \mathcal{U}(-3, 3)$ frames mediante `np.roll`
- **Person Dropout** (20% probabilidad): Eliminación aleatoria de una persona (excepto persona 0) estableciendo sus keypoints a cero

Balanceo de Clases mediante Augmentación El script de preparación de datos implementa augmentación adaptativa para balancear clases:

1. Se identifica la clase con mayor número de muestras (N_{max})
2. Para cada clase minoritaria, se generan aumentaciones hasta alcanzar N_{max} muestras
3. Solo se aumentan datos de entrenamiento (validación permanece sin aumentar)

4.4 Función Objetivo

La función de pérdida combina Focal Loss con Label Smoothing:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K \tilde{y}_{i,k} \cdot (1 - \hat{y}_{i,k})^\gamma \cdot \log(\hat{y}_{i,k}) \quad (16)$$

donde $\tilde{y}_{i,k}$ es la etiqueta suavizada:

$$\tilde{y}_{i,k} = (1 - \epsilon) \cdot y_{i,k} + \frac{\epsilon}{K} \quad (17)$$

con $\epsilon = 0.1$ (label smoothing) y $K = 5$ (número de clases).

5 Resultados Experimentales

5.1 Configuración Experimental

El modelo fue entrenado con la siguiente configuración de datos:

- **Entrada:** Tensores de forma $(N, 4, 2, 32, 25, 6)$ representando (batch, streams, coordenadas, frames, nodos, personas)
- **Clases:** 5 actividades (Social_People, Transit, Play_Object_Normal, Adult_Assisting, sliding)
- **Dataset:** 765 videos totales, aproximadamente 500 etiquetados manualmente
- **Split:** 80% entrenamiento, 20% validación/test
- **Parámetros del modelo:** $\sim 1.8\text{M}$ parámetros trainables

5.2 Resultados del Entrenamiento

El modelo alcanzó su mejor desempeño en la época 13 de 100 máximas, con early stopping implícito basado en validación:

Table 6. Métricas del mejor modelo durante entrenamiento.

Métrica	Valor
Mejor Accuracy (validación)	80.95%
Mejor F1-Score (validación)	0.7694
Época del mejor modelo	13

5.3 Métricas de Evaluación

Se utilizaron las siguientes métricas para evaluar el desempeño del modelo:

- **Accuracy:** Proporción de predicciones correctas
- **F1-Score (macro y weighted):** Media armónica de precisión y recall
- **Precision:** Proporción de predicciones positivas correctas
- **Recall:** Proporción de positivos reales identificados

5.4 Resultados en Conjunto de Test

La evaluación final en el conjunto de test (63 muestras) arrojó los siguientes resultados:

Table 7. Métricas globales de evaluación en test.

Métrica	Valor
Accuracy	82.54%
F1-Score (weighted)	0.7818
F1-Score (macro)	0.4288

Table 8. Métricas por clase en el conjunto de test.

Clase	Precision	Recall	F1-Score	Support
Social_People	0.8947	0.7727	0.8293	22
Transit	0.7955	1.0000	0.8862	35
Play_Object_Normal	0.0000	0.0000	0.0000	2
Adult_Assisting	0.0000	0.0000	0.0000	3
sliding	0.0000	0.0000	0.0000	1

5.5 Análisis de Resultados

Fortalezas del Modelo

1. **Arquitectura Multi-Stream de 4 canales:** La combinación de streams J, B, JM, BM captura información complementaria:
 - Joint (J): posición espacial absoluta de keypoints
 - Bone (B): estructura esquelética y orientación corporal
 - Joint Motion (JM): dinámica temporal de posiciones
 - Bone Motion (BM): cambios temporales en estructura ósea
2. **Alto rendimiento en clases mayoritarias:** Social_People (F1=0.83) y Transit (F1=0.89) muestran excelente clasificación.
3. **Procesamiento por persona:** La arquitectura procesa cada persona individualmente antes de agregar, permitiendo mejor modelado de comportamientos individuales.
4. **Integración de Objetos:** Los 8 nodos de objetos permiten al modelo aprender relaciones contextuales entre personas y equipamiento del parque.
5. **Grafo Panorámico:** El procesamiento conjunto de múltiples personas ($M = 6$) captura interacciones sociales y actividades grupales.

Desafíos Identificados

1. **Desbalance Severo de Clases:** Las clases minoritarias (Play_Object_Normal, Adult_Assisting, sliding) obtuvieron $F1=0$ debido a su baja representación en el conjunto de test (2, 3 y 1 muestras respectivamente). El modelo tiende a predecir las clases mayoritarias (Social_People y Transit).
2. **F1-Macro vs F1-Weighted:** La discrepancia entre F1-macro (0.43) y F1-weighted (0.78) evidencia el impacto del desbalance en las métricas agregadas.
3. **Ambigüedad Semántica:** Transiciones entre actividades y comportamientos mixtos dificultan la clasificación precisa.
4. **Variabilidad de Cámaras:** Diferentes ángulos, resoluciones y condiciones de iluminación entre cámaras afectan la generalización.

6 Discusión

6.1 Validación del Enfoque

Los resultados experimentales validan la hipótesis central de que MP-GCN puede adaptarse efectivamente desde entornos deportivos estructurados (voleibol) hacia espacios públicos no controlados (parques infantiles). La arquitectura multi-stream demuestra ser efectiva para capturar diferentes aspectos del movimiento humano.

La integración de objetos estáticos como nodos del grafo permite al modelo aprender relaciones contextuales relevantes para la clasificación de actividades en parques, donde la interacción con equipamiento es fundamental.

6.2 Comparación con Arquitectura Original

Table 9. Comparación entre MP-GCN original (voleibol) y PlaygroundGCN para parques.

Aspecto	MP-GCN Original	PlaygroundGCN
Dominio	Voleibol	Parques infantiles
Personas máx.	12	6
Nodos totales	17 per person	25 (17 + 8 objetos)
Streams	3 (J, B, V)	4 (J, B, JM, BM)
Canales input	3	2
Frames temporales	Variable	32
Clases	8	5
Entorno	Controlado	No controlado
Accuracy	–	82.54%

6.3 Limitaciones

1. **Tamaño del Dataset:** El número de videos anotados limita la capacidad de generalización del modelo.
2. **Clases Desbalanceadas:** Algunas actividades son naturalmente menos frecuentes, afectando el aprendizaje de esas clases.
3. **Dependencia de Detección de Poses:** Errores en YOLOv8-Pose se propagan al modelo de clasificación.
4. **Objetos Estáticos:** Los 8 objetos son fijos por cámara y no se adaptan dinámicamente.

7 Conclusiones

Este trabajo demuestra la viabilidad de adaptar arquitecturas estado del arte de reconocimiento de actividades grupales (MP-GCN) desde dominios estructurados (deportes) hacia entornos complejos no controlados (parques infantiles públicos). La implementación de PlaygroundGCN, una arquitectura multi-stream con cuatro representaciones complementarias (Joint, Bone, Joint Motion, Bone Motion), permite capturar diferentes aspectos del movimiento humano y sus dinámicas temporales, alcanzando una exactitud del 82.54% en el conjunto de test.

La integración de poses esqueléticas, objetos estáticos del entorno como nodos adicionales del grafo, y relaciones espaciotemporales mediante backbones ST-GCN paralelos con fusión tardía, proporciona una representación rica para la clasificación de 5 actividades relevantes en parques infantiles.

7.1 Contribuciones Principales

1. Desarrollo de PlaygroundGCN, una adaptación de MP-GCN con arquitectura multi-stream de 4 canales (J, B, JM, BM) para parques infantiles.
2. Pipeline completo de procesamiento desde video raw hasta predicciones de actividades, incluyendo extracción de poses, generación de streams, anotación de objetos y entrenamiento.
3. Integración de 8 objetos estáticos por cámara como nodos adicionales del grafo panorámico.
4. Dataset de 765 videos con aproximadamente 500 etiquetados manualmente mediante Label Studio.
5. Evaluación experimental alcanzando 82.54% de exactitud y 0.78 de F1-weighted en 5 clases de actividades.

7.2 Trabajo Futuro

Las siguientes extensiones podrían mejorar significativamente el sistema:

1. **Ampliación del Dataset:** Anotación de más videos para mejorar generalización y balanceo de clases.

2. **Semi-Supervised Learning:** Aprovechar videos no etiquetados mediante pseudo-labeling o consistency regularization.
3. **Detección de Anomalías:** Adaptar el sistema para detectar comportamientos riesgosos en tiempo real.
4. **Objetos Dinámicos:** Incorporar detección automática de objetos en lugar de coordenadas fijas.
5. **Fusión Multimodal:** Combinar features esqueléticas con embeddings visuales (ResNet, CLIP).
6. **Arquitecturas Híbridas:** Explorar combinaciones de GCN con Transformers para capturar dependencias de largo alcance.
7. **Deployment en Tiempo Real:** Optimización del modelo (quantization, pruning) para inferencia en dispositivos edge.
8. **Análisis Temporal Jerárquico:** Implementar modelos de secuencia (HMM, CRF) sobre predicciones consecutivas para suavizado temporal.

7.3 Contribuciones del Equipo

- **Antoine Ganem Nuñez:** Desarrollo del modelo MP-GCN multi-stream, implementación de training loop con Focal Loss, análisis de resultados, investigación bibliográfica y presentación final.
- **Hector Emil Grijalva Sanchez:** Apoyo en desarrollo del modelo, depuración de arquitectura ST-GCN, preparación de visualizaciones y presentación final.
- **Roberto Anwar Teigeiro Aguilar:** Desarrollo del pipeline de datos (YOLO, preprocesamiento, generación de streams), construcción de grafos panorámicos, documentación técnica y presentación final.
- **Fernando Antonio López García:** Apoyo en desarrollo del modelo, herramientas de anotación de objetos, redacción del reporte LaTeX y presentación final.

7.4 Reflexiones Personales

Antoine Ganem Nuñez Este proyecto me permitió profundizar en arquitecturas avanzadas de aprendizaje profundo aplicadas a datos estructurados complejos (grafos espaciotemporales multi-stream). El desafío de implementar los tres streams (Joint, Bone, Velocity) y fusionarlos correctamente me enseñó la importancia del diseño cuidadoso de arquitecturas. La experiencia adquirida en manejo de tensores multidimensionales y debugging de GCNs será invaluable para proyectos futuros.

Hector Emil Grijalva Sanchez Trabajar en este proyecto me brindó una perspectiva práctica sobre los desafíos reales del machine learning aplicado. La implementación de Focal Loss y técnicas de balanceo de clases me enseñó que el entrenamiento de modelos va más allá de la arquitectura: el manejo de datos desbalanceados es crucial. Aprendí la importancia de la validación rigurosa y la comunicación clara de limitaciones.

Roberto Anwar Teigeiro Aguilar La construcción del pipeline de datos desde video raw hasta tensores multi-stream fue una experiencia transformadora. Implementar la generación de streams (especialmente el Bone stream con las conexiones COCO correctas) consolidó mis conocimientos en procesamiento de datos estructurados. El desarrollo del preprocesamiento robusto me enseñó que la calidad de los datos es tan importante como la arquitectura del modelo.

Fernando Antonio López García Este proyecto me permitió desarrollar habilidades complementarias a la implementación técnica: documentación clara, redacción académica formal y comunicación efectiva de conceptos técnicos complejos. La elaboración de este reporte en formato Springer LNCS me familiarizó con estándares de publicación científica. El proceso de documentar la arquitectura multi-stream y el pipeline de preprocesamiento me ayudó a consolidar mi comprensión del sistema completo.

References

1. Zhang, W., Chen, H., Li, Y., & Wang, X. (2024). *Multi-scale Panoramic Graph Convolutional Networks for Group Activity Recognition*. In: European Conference on Computer Vision (ECCV), pp. 234–249. Springer, Cham.
2. Yan, S., Xiong, Y., & Lin, D. (2018). *Spatial Temporal Graph Convolutional Networks for Skeleton-Based Action Recognition*. In: AAAI Conference on Artificial Intelligence, vol. 32, no. 1, pp. 7444–7452.
3. Jocher, G., Chaurasia, A., & Qiu, J. (2023). *YOLO by Ultralytics (Version 8.0. 0)* [Computer software]. Disponible en: <https://github.com/ultralytics/ultralytics>
4. Zhang, Y., Sun, P., Jiang, Y., Yu, D., Weng, F., Yuan, Z., Luo, P., Liu, W., & Wang, X. (2022). *ByteTrack: Multi-Object Tracking by Associating Every Detection Box*. In: European Conference on Computer Vision (ECCV), pp. 1–21. Springer, Cham.
5. Heartex. (2020). *Label Studio: Open Source Data Labeling Tool*. Disponible en: <https://labelstud.io>
6. Kipf, T. N., & Welling, M. (2017). *Semi-Supervised Classification with Graph Convolutional Networks*. In: International Conference on Learning Representations (ICLR).
7. Lin, T. Y., Maire, M., Belongie, S., Hays, J., Perona, P., Ramanan, D., Dollár, P., & Zitnick, C. L. (2014). *Microsoft COCO: Common Objects in Context*. In: European Conference on Computer Vision (ECCV), pp. 740–755. Springer, Cham.
8. Lin, T. Y., Goyal, P., Girshick, R., He, K., & Dollár, P. (2017). *Focal Loss for Dense Object Detection*. In: IEEE International Conference on Computer Vision (ICCV), pp. 2980–2988.
9. Shorten, C., & Khoshgoftaar, T. M. (2019). *A Survey on Image Data Augmentation for Deep Learning*. Journal of Big Data, vol. 6, no. 1, pp. 1–48.
10. Pedregosa, F., et al. (2011). *Scikit-learn: Machine Learning in Python*. Journal of Machine Learning Research, vol. 12, pp. 2825–2830.
11. Kingma, D. P., & Ba, J. (2014). *Adam: A Method for Stochastic Optimization*. arXiv preprint arXiv:1412.6980.

12. Ioffe, S., & Szegedy, C. (2015). *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*. In: International Conference on Machine Learning (ICML), pp. 448–456.